

1 確率分布

1.1 確率変数と確率分布

各値に対応して確率が定まるような変数を **確率変数** という。たとえば、2 枚のコインを同時に投げるとき、表のコインの枚数 X は確率変数である。

確率変数 X が a である確率を $P(X = a)$ 、 a 以上 b 以下である確率を $P(a \leq X \leq b)$ のように表す。たとえば、2 枚のコインを同時に投げるとき、表のコインの枚数を X とすると $P(X = 1) = \frac{{}_2C_1}{2^2} = \frac{1}{2}$ である。

確率変数 X のとりうる値 x_1, x_2, \dots, x_n とそれぞれの値をとる確率 p_1, p_2, \dots, p_n の対応関係を **確率分布** といい、以下のような表で書き表す。

X	x_1	x_2	\cdots	x_n	計
P	p_1	p_2	\cdots	p_n	1

確率分布が上の表で与えられるとき、 $\sum_{k=1}^n x_k p_k$ を確率変数 X の **期待値** または **平均** といい、 $E(X)$ または m で表す。

確率変数 X の各値と平均 m の離れ具合を表す確率変数 $(X - m)^2$ の期待値 $E((X - m)^2)$ を確率変数 X の **分散** といい、 $V(X)$ で表す。 $V(X)$ は、 X^2 の期待値 $E(X^2)$ と X の期待値 $E(X)$ を用いて

$$V(X) = E(X^2) - \{E(X)\}^2$$

とも表される。また、分散の正の平方根 $\sqrt{V(X)}$ を確率変数 X の **標準偏差** といい、 $\sigma(X)$ で表す。

1.2 確率変数の和や積

互いに独立な確率変数 X, Y に対して

$$E(X + Y) = E(X) + E(Y)$$

$$E(XY) = E(X)E(Y)$$

$$V(X + Y) = V(X) + V(Y)$$

が成り立つ。

1.3 二項分布

1 回の試行で事象 A が起こる確率が p であるとき、この試行を n 回行う反復試行において A がちょうど r 回起こる確率は

$${}_nC_rp^rq^{n-r} \quad (\text{ただし, } q = 1 - p)$$

である。つまり、 A の起こる回数を X とすると、確率変数 X の確率分布は以下の表で与えられる。

X	0	1	...	r	...	n	計
P	${}_nC_0q^n$	${}_nC_1pq^{n-1}$...	${}_nC_rp^rq^{n-r}$...	${}_nC_np^n$	1

このような確率分布を **二項分布** といい、 $B(n, p)$ で表す。確率変数 X が二項分布 $B(n, p)$ に従うとき、その期待値、分散、標準偏差に対して

$$E(X) = np$$

$$V(X) = npq$$

$$\sigma(X) = \sqrt{npq}$$

が成り立つ。

1.4 正規分布

連続した値をとる確率変数を **連続型確率変数** という。連続型確率変数の確率分布は表で書き表せないで、グラフで表す。

常に $f(x) \geq 0$ で、どんな値 a, b に対しても $P(a \leq x \leq b) = \int_a^b f(x) dx$ であるような関数 $f(x)$ を **確率密度関数** という。確率密度関数をグラフに表した曲線 $y = f(x)$ を **分布曲線** という。

m を実数、 σ を正の実数とすると、関数

$$f(X) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(X-m)^2}{2\sigma^2}}$$

は確率変数 X の確率密度関数となっている。このような確率分布を **正規分布** といい、 $N(m, \sigma^2)$ で表す。確率変数 X が正規分布 $N(m, \sigma^2)$ に従うとき、その期待値、分散、標準偏差に対して

$$E(X) = m$$

$$V(X) = \sigma^2$$

$$\sigma(X) = \sigma$$

が成り立つ。

正規分布 $N(0, 1)$ をとくに **標準正規分布** という。確率変数 X が正規分布 $N(m, \sigma^2)$ に従うとき、

$$Z = \frac{X - m}{\sigma}$$

とおくと、確率変数 Z は標準正規分布 $N(0, 1)$ に従う。

2 統計的な推測

2.1 母集団と標本

特性を表す数量を **変量** という。大きさ N の母集団において、変量 x のとりうる異なる値を

$$x_1, x_2, \dots, x_n$$

とし、それぞれの値をとる個体の個数を

$$f_1, f_2, \dots, f_n$$

とする。この母集団から 1 個の個体を無作為に抽出し、変量 x の値を X とするとき、確率変数 X の確率分布は以下の表のようになる。

X	x_1	x_2	\cdots	x_n	計
P	$\frac{f_1}{N}$	$\frac{f_2}{N}$	\cdots	$\frac{f_n}{N}$	1

この X の確率分布を **母集団分布** という。また、確率変数 X の期待値、標準偏差をそれぞれ **母平均**、**母標準偏差** といい、 m 、 σ で表す。

母集団から大きさ n の無作為標本を抽出し、それらの変量 x の値を X_1, X_2, \dots, X_n とするとき、

$$\bar{X} = \frac{X_1 + X_2 + \cdots + X_n}{n}$$

を **標本平均** という。

母平均 m 、母標準偏差 σ の母集団から大きさ n の無作為標本を抽出するとき、その標本平均 \bar{X} の期待値 $E(\bar{X})$ と標準偏差 $\sigma(\bar{X})$ は

$$E(\bar{X}) = m, \quad \sigma(\bar{X}) = \frac{\sigma}{\sqrt{n}}$$

である。

母集団の中で特性 A をもつものの割合を、その特性 A の **母比率** といい、抽出された標本の中で特性 A をもつものの割合を **標本比率** という。

標本の中で特性 A をもつものの個数を考えるには、特性 A をもつとき $X_k = 1$ 、特性 A をもたないとき $X_k = 0$ として考えればよい。

$T = \sum_{k=1}^n X_k$ が特性 A をもつものの個数を表す確率変数となっている。

標本の大きさを n 、母比率を p とすると、確率変数 T は二項分布 $B(n, p)$ に従う。標本平均 $\bar{X} = \frac{T}{n}$ は特性 A の標本比率 R を表すので、 n が大きいとき、標本比率 R は近似的に正規分布 $N\left(p, \frac{pq}{n}\right)$ に従う。ただし、 $q = 1 - p$ とする。

＊ **標本平均の標準偏差**であるという点に注意する。

2.2 推定

母集団から抽出した大きさ n の無作為標本について平均値が \bar{X} 、標準偏差が S であるとき、母平均の信頼度 95% の信頼区間は

$$\left[\bar{X} - 1.96 \cdot \frac{S}{\sqrt{n}}, \quad \bar{X} + 1.96 \cdot \frac{S}{\sqrt{n}} \right]$$

である。また、その標本比率が R であるとき、母比率の信頼度 95% の信頼区間は

$$\left[R - 1.96 \sqrt{\frac{R(1-R)}{n}}, \quad R + 1.96 \sqrt{\frac{R(1-R)}{n}} \right]$$

である。

＊ 1.96 という値は、正規分布において平均から両側 95% の範囲、すなわち、片側 47.5% の区間を表す。信頼度 90% で考えたければ 1.65、信頼度 99% で考えたければ 2.58 のようにすればよい。

2.3 仮説検定

ある仮説が正しいか否かを統計学的に検証することを **仮説検定** という。「特別なことが起こっていない」という仮説 H_0 を **帰無仮説** といい、それと対立する「特別なことが起こっている」という仮説 H_1 を **対立仮説** という。帰無仮説 H_0 が採択されると、「特別なことが起こっていない」という結論に帰着し、帰無仮説 H_0 が棄却されると、対立仮説が支持される。

〔例〕 コインを 400 回投げて、表が 218 回出た。有意水準を 5% として、次のことがいえると判断してよいかをそれぞれ検定せよ。

- (1) このコインは表が出やすい。
- (2) このコインは、表と裏の出方に偏りがある。